## Práctica 2: Limpieza y análisis de datos

Autor: Victor Mascarell Ascó

1 de enero 2020

## Descripción del dataset

En esta segunda práctica enmarcada dentro de la asignatura Tipología y Ciclo de Vida del Dato del Master en ciencia de datos de la UOC vamos a tratar el Dataset Cancer Breast que podemos encontrar en el siguiente enlace del repositorio de Kaggle: <a href="https://www.kaggle.com/uciml/breast-cancer-wisconsin-data">https://www.kaggle.com/uciml/breast-cancer-wisconsin-data</a>.

El dataset contiene 569 registros de casos de cáncer de pecho con 30 atributos descriptivos de los mismos, 1 atributo clasificatorio en función de si el tumor es benigno o maligno y un atributo de ID. Los atributos descriptivos describen al media (mean), error estándar (se) y la media de los tres valores más grandes (worst) de las células del tumor a través de 10 de sus características. Así las 30 variables descriptivas sería:

- 1. radius mean (Variable continúa)
- 2. texture\_mean (Variable continúa)
- 3. perimeter\_mean (Variable continúa)
- 4. area\_mean (Variable continúa)
- 5. smoothness mean (Variable continúa)
- 6. compactness mean (Variable continúa)
- 7. concavity\_mean (Variable continúa)
- 8. concave.points mean (Variable continúa)
- 9. symmetry\_mean (Variable continúa)
- 10. fractal\_dimension\_mean (Variable continúa)
- 11. radius se (Variable continúa)
- 12. texture se (Variable continúa)
- 13. perimeter se (Variable continúa)

- 14. area se (Variable continúa)
- 15. smoothness se (Variable continúa)
- 16. compactness se (Variable continúa)
- 17. concavity se (Variable continúa)
- 18. concave.points se (Variable continúa)
- 19. symmetry se (Variable continúa)
- 20. fractal dimension se (Variable continúa)
- 21. radius worst (Variable continúa)
- 22. texture worst (Variable continúa)
- 23. perimeter worst (Variable continúa)
- 24. area worst (Variable continúa)
- 25. smoothness worst (Variable continúa)
- 26. compactness worst (Variable continúa)
- 27. concavity worst (Variable continúa)
- 28. concave.points worst (Variable continúa)
- 29. symmetry\_worst (Variable continúa)
- 30. fractal\_dimension\_worst (Variable continúa):

#### Los otros campos serían:

- 31. id (Dato continúo): Identificador único.
- 32. diagnosis (Dato categórico): Diagnóstico.

Este dataset es importante ya que nos ofrece la información necesario de casos de cáncer de mama anteriores, lo que nos puede ayudar a construir un modelo predictivo para diagnosticar si los tumores de mama encontrados son malignos o benignos. Así, el objetivo final será crear un modelo que nos permita clasificar y predecir si el cáncer de mama es maligno o benigno.

## Integración y selección de los datos de interés a analizar

Para realizar el modelo descartaremos la variable de ID, ya que no nos aporta información alguna sobre las posibles características del tumor. Y por otro lado dejaremos la variable clasificatoria para comprobar la fiabilidad del modelo. No obstante, en los siguientes apartados, también utilizaremos la variable clasificatoria para analizar los datos y concluir que variables descriptivas son las más adecuadas para construir el modelo.

## Limpieza de los datos

## Lectura y carga de datos

En primer lugar procedemos a cargar el fichero de datos. Observar si los datos se han cargado correctamente.

```
# Con read.csv carcamos el fichero
data <- read.csv('data.csv',stringsAsFactors = FALSE)</pre>
# Utilizamos dim para comprobar el número de registros
dim(data)
## [1] 569
# Utilizamos str para ver el tipo de datos
str(data)
## 'data.frame':
                    569 obs. of
                                 33 variables:
## $ id
                                     842302 842517 84300903 84348301
                              : int.
84358402 843786 844359 84458202 844981 84501001 ...
                                     "M" "M" "M" "M" ...
    $ diagnosis
                             : chr
## $ radius mean
                                     18 20.6 19.7 11.4 20.3 ...
                             : num
## $ texture mean
                                    10.4 17.8 21.2 20.4 14.3 ...
                             : num
## $ perimeter mean
                                    122.8 132.9 130 77.6 135.1 ...
                             : num
```

```
## $ area mean
                                 1001 1326 1203 386 1297 ...
                          : num
## $ smoothness mean
                         : num 0.1184 0.0847 0.1096 0.1425 0.1003
## $ compactness mean
                          : num 0.2776 0.0786 0.1599 0.2839 0.1328
## $ concavity mean
                     : num 0.3001 0.0869 0.1974 0.2414
0.198 ...
## $ concave.points mean : num 0.1471 0.0702 0.1279 0.1052 0.1043
. . .
## $ symmetry mean
                          : num 0.242 0.181 0.207 0.26 0.181 ...
## $ fractal dimension mean : num 0.0787 0.0567 0.06 0.0974
0.0588 ...
## $ radius se
                                 1.095 0.543 0.746 0.496 0.757 ...
                    : num
## $ texture se
                         : num 0.905 0.734 0.787 1.156 0.781 ...
                        : num 8.59 3.4 4.58 3.44 5.44 ...
## $ perimeter se
## $ area se
                                 153.4 74.1 94 27.2 94.4 ...
                          : num
                      : num
## $ smoothness se
                                 0.0064 0.00522 0.00615 0.00911
0.01149 ...
## $ compactness se : num 0.049 0.0131 0.0401 0.0746
0.0246 ...
## $ concavity se
                          : num 0.0537 0.0186 0.0383 0.0566 0.0569
## $ concave.points se : num 0.0159 0.0134 0.0206 0.0187 0.0188
## $ symmetry se
                    : num 0.03 0.0139 0.0225 0.0596
0.0176 ...
## $ fractal dimension se : num 0.00619 0.00353 0.00457 0.00921
0.00511 ...
                                 25.4 25 23.6 14.9 22.5 ...
## $ radius worst
                     : num
## $ texture worst
                                 17.3 23.4 25.5 26.5 16.7 ...
                          : num
## $ perimeter worst
                                 184.6 158.8 152.5 98.9 152.2 ...
                          : num
## $ area worst
                                 2019 1956 1709 568 1575 ...
                          : num
## $ smoothness worst
                                 0.162 0.124 0.144 0.21 0.137 ...
                         : num
## $ compactness worst
                                 0.666 0.187 0.424 0.866 0.205 ...
                          : num
## $ concavity worst
                          : num 0.712 0.242 0.45 0.687 0.4 ...
## $ concave.points worst : num 0.265 0.186 0.243 0.258 0.163 ...
## $ symmetry worst
                          : num 0.46 0.275 0.361 0.664 0.236 ...
## $ fractal dimension worst: num 0.1189 0.089 0.0876 0.173
```

```
## $ X
                             : logi NA NA NA NA NA NA ...
# Imprimimos las primeras filas del dataset
head(data)
##
           id diagnosis radius mean texture mean perimeter mean
area mean
       842302
## 1
                      М
                              17.99
                                           10.38
                                                          122.80
1001.0
## 2
     842517
                              20.57
                                           17.77
                                                          132.90
                      М
1326.0
## 3 84300903
                              19.69
                                           21.25
                      M
                                                          130.00
1203.0
## 4 84348301
                              11.42
                                           20.38
                                                          77.58
                      М
386.1
## 5 84358402
                      М
                              20.29
                                           14.34
                                                          135.10
1297.0
## 6 843786
                      М
                              12.45
                                           15.70
                                                           82.57
477.1
     smoothness mean compactness mean concavity mean
concave.points mean
## 1
             0.11840
                              0.27760
                                              0.3001
0.14710
## 2
             0.08474
                              0.07864
                                              0.0869
0.07017
## 3
             0.10960
                              0.15990
                                              0.1974
0.12790
## 4
             0.14250
                              0.28390
                                              0.2414
0.10520
## 5
             0.10030
                              0.13280
                                              0.1980
0.10430
## 6
             0.12780
                              0.17000
                                              0.1578
0.08089
     symmetry mean fractal dimension mean radius se texture se
perimeter se
## 1
            0.2419
                                  0.07871
                                             1.0950
                                                         0.9053
8.589
## 2
            0.1812
                                  0.05667
                                             0.5435
                                                         0.7339
3.398
## 3
            0.2069
                                  0.05999
                                             0.7456
                                                         0.7869
```

0.0768 ...

```
4.585
## 4
            0.2597
                                  0.09744
                                            0.4956
                                                        1.1560
3.445
## 5
            0.1809
                                  0.05883
                                            0.7572
                                                        0.7813
5.438
## 6
            0.2087
                                  0.07613
                                             0.3345
                                                        0.8902
2.217
     area se smoothness se compactness se concavity se
concave.points se
## 1 153.40
                 0.006399
                                  0.04904
                                               0.05373
0.01587
## 2 74.08
                 0.005225
                                  0.01308
                                               0.01860
0.01340
## 3 94.03
                                  0.04006
                  0.006150
                                               0.03832
0.02058
## 4 27.23
                  0.009110
                                  0.07458
                                               0.05661
0.01867
## 5 94.44
                  0.011490
                                  0.02461
                                               0.05688
0.01885
## 6 27.19
                  0.007510
                                  0.03345
                                               0.03672
0.01137
    symmetry se fractal dimension se radius worst texture worst
##
## 1
        0.03003
                             0.006193
                                             25.38
                                                           17.33
## 2
        0.01389
                             0.003532
                                             24.99
                                                           23.41
## 3
        0.02250
                             0.004571
                                             23.57
                                                           25.53
## 4
        0.05963
                             0.009208
                                             14.91
                                                           26.50
## 5
        0.01756
                             0.005115
                                             22.54
                                                           16.67
## 6
        0.02165
                             0.005082
                                            15.47
                                                           23.75
##
    perimeter worst area worst smoothness worst compactness worst
## 1
             184.60
                         2019.0
                                          0.1622
                                                            0.6656
## 2
              158.80
                        1956.0
                                          0.1238
                                                            0.1866
             152.50
## 3
                        1709.0
                                          0.1444
                                                            0.4245
## 4
              98.87
                        567.7
                                          0.2098
                                                            0.8663
## 5
             152.20
                        1575.0
                                          0.1374
                                                            0.2050
## 6
              103.40
                          741.6
                                          0.1791
                                                            0.5249
##
    concavity worst concave.points worst symmetry worst
## 1
              0.7119
                                   0.2654
                                                  0.4601
## 2
              0.2416
                                   0.1860
                                                  0.2750
## 3
              0.4504
                                   0.2430
                                                  0.3613
```

```
## 4
               0.6869
                                      0.2575
                                                       0.6638
## 5
               0.4000
                                      0.1625
                                                       0.2364
## 6
               0.5355
                                      0.1741
                                                       0.3985
##
     fractal dimension worst
## 1
                       0.11890 NA
## 2
                       0.08902 NA
## 3
                       0.08758 NA
## 4
                       0.17300 NA
## 5
                       0.07678 NA
## 6
                       0.12440 NA
```

Podemos comprobar que los datos se han cargado correctamente a excepción de la variable diagnosis que nos interesaría tenerla en factor y nos la carga con char . También nos ha cargado un atributo de más (X) que parece contener valores nulos. Este lo trataremos en el siguiente apartado. Ahora procederemos a cambiar el tipo de dato de diagnosis a factor

```
# Pasamos a factor diagnosis
data$diagnosis <- factor(data$diagnosis)

# Comprobamos el resultado
str(data$diagnosis)

## Factor w/ 2 levels "B", "M": 2 2 2 2 2 2 2 2 2 2 2 ...</pre>
```

### ¿Los datos contienen ceros o elementos vacíos?

Procedemos a calcular los valores vacíos de cada atributo

```
# Sumamos valores vacíos
colSums(is.na(data))
##
                          id
                                            diagnosis
radius mean
                                                     0
##
                           0
0
##
               texture mean
                                      perimeter mean
area mean
                           0
                                                     0
##
0
##
           smoothness mean
                                    compactness mean
concavity mean
```

```
##
                           0
                                                     0
0
##
       concave.points mean
                                        symmetry mean
fractal dimension mean
##
                           0
                                                     0
0
##
                  radius se
                                           texture se
perimeter se
##
                           0
                                                     0
0
##
                                        smoothness se
                    area se
compactness se
##
                           0
                                                     0
0
##
               concavity se
                                    concave.points se
symmetry se
##
                           0
                                                     0
0
##
      fractal dimension se
                                         radius worst
texture worst
##
                           0
                                                     0
0
##
           perimeter worst
                                           area worst
smoothness worst
##
                           0
                                                     0
0
##
         compactness worst
                                      concavity worst
concave.points worst
##
                           0
                                                     0
0
##
             symmetry worst fractal dimension worst
Х
##
                           0
                                                     0
569
```

Podemos comprobar que la última columna es un error de carga y solo contiene valores vacíos por lo que procedemos a eliminarla, aprovechamos para eliminar también id. Si tuviéramos valores vacíos dentro de los campos de interés podríamos optar por sustituirlos por la media o eliminar el registro en función del interés.

```
# Selectionamos las columnas deseadas
data <- data[, 2:32]</pre>
```

De la misma forma vamos a comprobar si existen 0 en los atributos del dataset.

```
# Sumamos valores = 0 por columnas
colSums(data==0)
##
                  diagnosis
                                         radius mean
texture mean
                          0
                                                   0
##
0
            perimeter mean
                                           area mean
smoothness mean
                          0
                                                   0
##
0
          compactness mean
                                      concavity mean
concave.points mean
##
                          0
                                                  13
13
##
             symmetry mean fractal dimension mean
radius se
                          0
                                                   0
##
0
##
                 texture se
                                        perimeter se
area se
                          0
                                                   0
##
             smoothness se
                                      compactness se
concavity se
##
                          0
                                                   0
13
##
         concave.points se
                                         symmetry se
fractal dimension se
##
                         13
                                                   0
0
              radius worst
                                       texture worst
perimeter worst
##
                          0
                                                   0
0
##
                 area worst
                                    smoothness worst
```

```
compactness_worst
## 0 0
0
## concavity_worst concave.points_worst
symmetry_worst
## 13 13
0
## fractal_dimension_worst
## 0
```

Observamos que sí. Comprobamos si los registros que contienen 0 son los mismos.

```
# Imprimos las filas que contienen 0 en concave.points se
print(data[data$concave.points se==0,])
       diagnosis radius mean texture mean perimeter mean area mean
## 102
               В
                        6.981
                                      13.43
                                                      43.79
                                                                 143.5
## 141
                        9.738
                                      11.97
                В
                                                      61.24
                                                                 288.5
## 175
                       10.660
                                      15.15
                                                      67.49
               В
                                                                 349.6
                                      14.45
## 176
                                                      54.42
               В
                        8.671
                                                                 227.2
## 193
                        9.720
                                      18.22
                                                      60.73
                                                                 288.1
                В
## 315
                                      18.60
                                                      54.09
                                                                 221.2
               В
                        8.597
                                      16.84
                                                      55.27
## 392
               В
                        8.734
                                                                 234.3
## 474
               В
                       12.270
                                      29.97
                                                      77.42
                                                                 465.4
                                                      47.98
## 539
               В
                        7.729
                                      25.49
                                                                 178.8
## 551
                       10.860
                                      21.48
                                                      68.51
                                                                 360.5
               В
## 558
               В
                        9.423
                                      27.88
                                                      59.26
                                                                 271.3
## 562
                В
                       11.200
                                      29.37
                                                      70.67
                                                                 386.0
## 569
               В
                        7.760
                                      24.54
                                                      47.92
                                                                 181.0
       smoothness mean compactness mean concavity mean
concave.points mean
## 102
                0.11700
                                  0.07568
                                                        0
0
## 141
                                  0.04102
                                                        0
                0.09250
## 175
                0.08792
                                  0.04302
                                                        0
## 176
                0.09138
                                  0.04276
                                                        0
                0.06950
## 193
                                  0.02344
                                                        0
```

0 ## 315	0.10740	0.05847	0	
0	0.10740	0.03047	Ü	
## 392 0	0.10390	0.07428	0	
	0.07699	0.03398	0	
0 ## 539	0.08098	0.04878	0	
0	0.08098	0.04070	Ü	
## 551 0	0.07431	0.04227	0	
	0.08123	0.04971	0	
0 ## 562	0.07449	0.03558	0	
0				
## 569 0	0.05263	0.04362	0	
## symmet	ry_mean fract	al_dimension_mean 1	radius_se textu	re_se
<pre>perimeter_se ## 102</pre>	0.1930	0.07818	0.2241 1	.5080
1.553			-	
## 141	0.1903	0.06422	0.1988 0	.4960
1.218 ## 175	0.1928	0.05975	0.3309 1	.9250
2.155				
## 176 1.435	0.1722	0.06724	0.2204 0	.7873
## 193	0.1653	0.06447	0.3539 4	.8850
2.230 ## 315	0.2163	0.07359	0.3368 2	.7770
2.222	0.2103	0.07333	0.3300 2	• 1110
## 392	0.1985	0.07098	0.5169 2	.0790
3.167 ## 474	0.1701	0.05960	0.4455 3	.6470
2.884 ## 539	0.1870	0.07285	0.3777 1	.4620
2.492	0.10/0	0.07265	0.3/// 1	• 4020
## 551	0.1661	0.05948	0.3163 1	.3040
2.115 ## 558	0.1742	0.06059	0.5375 2	.9270

3.618 ## 562	0.106	50	0.05502	0.3141	3.8960
2.041		_			
## 569 2.548	0.158	37	0.05884	0.3857	1.4280
	area_se smoo	othness_se	compactness_se	concavity_	se
concave	e.points_se				
## 102 0	9.833	0.010190	0.010840		0
## 141 0	12.260	0.006040	0.005656		0
	21.980	0.008713	0.010170		0
	11.360	0.009172	0.008007		0
## 193	21.690	0.001713	0.006736		0
	17.810	0.020750	0.014030		0
0 ## 392	28.850	0.015820	0.019660		0
0 ## 474	35.130	0.007339	0.008243		0
0					
## 539 0	19.140	0.012660	0.009692		0
	20.670	0.009579	0.011040		0
	29.110	0.011590	0.011240		0
## 562	22.810	0.007594	0.008878		0
	19.150	0.007189	0.004660		0
0					
##		fractal_d	imension_se rad	<del>-</del>	<del>-</del>
## 102	0.02659		0.004100	7.930	19.54
## 141	0.02277		0.003220	10.620	14.10
## 175	0.03265		0.001002	11.540	19.20
## 176	0.02711		0.003399	9.262	17.04
## 193	0.03799		0.001688	9.968	20.83

##	315	0.06146	0.00682	20 8.95	52	22.44
##	392	0.01865	0.00673	36 10.17	70	22.80
##	474	0.03141	0.00313	36 13.45	50	38.05
##	539	0.02882	0.00687	72 9.07	77	30.92
##	551	0.03004	0.00222	28 11.66	50	24.77
##	558	0.03004	0.00332	10.49	0	34.24
##	562	0.01989	0.0017	73 11.92	20	38.30
##	569	0.02676	0.00278	9.45	56	30.37
##		<pre>perimeter_worst</pre>	area_worst smoo	othness_worst	compactnes	ss_worst
##	102	50.41	185.2	0.15840		0.12020
##	141	66.53	342.9	0.12340		0.07204
##	175	73.20	408.3	0.10760		0.06791
##	176	58.36	259.2	0.11620		0.07057
##	193	62.25	303.8	0.07117		0.02729
##	315	56.65	240.1	0.13470		0.07767
##	392	64.01	317.0	0.14600		0.13100
##	474	85.08	558.9	0.09422		0.05213
##	539	57.17	248.0	0.12560		0.08340
##	551	74.08	412.3	0.10010		0.07348
##	558	66.50	330.6	0.10730		0.07158
##	562	75.19	439.6	0.09267		0.05494
##	569	59.16	268.6	0.08996		0.06444
##		concavity_worst	concave.points_	_worst symmetr	ry_worst	
##	102	0		0	0.2932	
##	141	0		0	0.3105	
##	175	0		0	0.2710	
##	176	0		0	0.2592	
##	193	0		0	0.1909	
##	315	0		0	0.3142	
	392	0		0	0.2445	
##	474	0		0	0.2409	
	539	0		0	0.3058	
##	551	0		0	0.2458	
##	558	0		0	0.2475	
	562	0		0	0.1566	
	569	0		0	0.2871	
##		fractal_dimension	on_worst			

```
## 102
                         0.09382
## 141
                         0.08151
## 175
                         0.06164
## 176
                         0.07848
## 193
                         0.06559
## 315
                         0.08116
## 392
                         0.08865
## 474
                         0.06743
## 539
                         0.09938
## 551
                         0.06592
## 558
                         0.06969
## 562
                         0.05905
## 569
                         0.07039
```

Son la mismas filas y como vemos la media, el error estándar y el "worst" dan 0, caso bastante improbable. Procedemos a eliminar estos registros del dataset ya que contiene más de 500.

```
# Eliminamos los valores
data <- data[data$concave.points se!=0,]</pre>
# Comprobamos de nuevo con el sumatoria de "0" y la dimentsión.
colSums(data==0)
##
                  diagnosis
                                         radius mean
texture mean
##
                          0
                                                    0
0
##
            perimeter mean
                                           area mean
smoothness mean
                          0
                                                    0
##
0
          compactness mean
                                      concavity mean
concave.points mean
                                                    0
##
                          0
0
##
             symmetry mean fractal dimension mean
radius se
                          0
##
                                                    0
0
##
                                        perimeter se
                 texture se
```

```
area se
##
                           0
                                                     n
0
##
              smoothness se
                                       compactness se
concavity se
##
                           0
                                                     0
0
##
         concave.points se
                                          symmetry se
fractal dimension se
##
                           0
                                                     0
0
##
               radius worst
                                        texture worst
perimeter worst
##
                           0
                                                     O
0
##
                 area worst
                                     smoothness worst
compactness worst
##
                           0
                                                     0
0
##
            concavity worst
                                concave.points worst
symmetry worst
##
                           0
                                                     0
## fractal dimension worst
##
                           0
dim(data)
## [1] 556
             31
```

Para la predicción utilizaremos la media de las características, ya que se considera más representativa en este caso. Por lo que vamos a proceder a eliminar las columnas relacionadas con contienen el error estándar y los peores valores o "worst", quedándonos solo con 10 variables.

```
# Eliminamos las variables que contienen el SE y el "worst" data <- data[, 1:11]
```

#### Tratamiento de valores extremos

A continuación procedemos a observar los valores extremos o outliers

```
boxplot.stats(data$radius mean)
## $stats
## [1] 7.691 11.760 13.455 16.050 22.270
##
## $n
## [1] 556
##
## $conf
## [1] 13.16754 13.74246
##
## Sout
## [1] 25.22 24.25 23.27 27.22 23.29 28.11 23.21 23.51 25.73 27.42
23.09
## [12] 24.63
boxplot.stats(data$texture mean)
## $stats
## [1] 9.710 16.175 18.855 21.750 29.810
##
## $n
## [1] 556
##
## $conf
## [1] 18.48144 19.22856
##
## $out
## [1] 32.47 33.81 39.28 33.56 31.12 30.72 30.62
boxplot.stats(data$perimeter mean)
## $stats
## [1] 48.34 75.80 87.09 105.40 147.30
##
## $n
## [1] 556
##
## $conf
## [1] 85.1066 89.0734
```

```
##
## $out
## [1] 171.5 152.8 166.2 152.1 182.1 158.9 188.5 153.5 155.1 174.2
186.9
## [12] 152.1 165.5
boxplot.stats(data$area mean)
## $stats
## [1] 170.40 427.60 557.65 798.30 1347.00
##
## $n
## [1] 556
##
## $conf
## [1] 532.8105 582.4895
##
## $out
## [1] 1404 1878 1509 1761 1686 2250 1685 2499 1670 1364 1419 1491
1747 2010
## [15] 1546 1482 1386 1407 1384 2501 1682 1841 1479
boxplot.stats(data$smoothness mean)
## $stats
## [1] 0.062510 0.086650 0.096035 0.105400 0.133500
##
## $n
## [1] 556
##
## $conf
## [1] 0.09477862 0.09729138
##
## $out
## [1] 0.1425 0.1398 0.1447 0.1634 0.1371
boxplot.stats(data$compactness mean)
## $stats
## [1] 0.019380 0.066525 0.095090 0.130600 0.223900
```

```
##
## $n
## [1] 556
##
## Sconf
## [1] 0.09079653 0.09938347
##
## $out
## [1] 0.2776 0.2839 0.2396 0.2458 0.2293 0.2276 0.3454 0.2665 0.2768
0.2867
## [11] 0.2832 0.2413 0.2284 0.3114 0.2364 0.2363 0.2576 0.2770
boxplot.stats(data$concavity mean)
## $stats
## [1] 0.000692 0.030740 0.064905 0.132350 0.281000
##
## $n
## [1] 556
##
## $conf
## [1] 0.05809643 0.07171357
##
## $out
## [1] 0.3001 0.3130 0.3754 0.3339 0.4264 0.3003 0.4268 0.4108 0.2871
0.3523
## [11] 0.3201 0.3176 0.2914 0.3368 0.3189 0.3635 0.3174 0.3514
boxplot.stats(data$concave.points mean)
## $stats
## [1] 0.001852 0.020890 0.034840 0.074855 0.152000
##
## $n
## [1] 556
##
## $conf
## [1] 0.03122397 0.03845603
##
```

```
## $out
## [1] 0.1604 0.1845 0.1823 0.2012 0.1878 0.1620 0.1595 0.1913 0.1562
0.1689
boxplot.stats(data$symmetry mean)
## $stats
## [1] 0.11670 0.16190 0.17925 0.19580 0.24590
##
## $n
## [1] 556
##
## $conf
## [1] 0.1769785 0.1815215
##
## $out
## [1] 0.2597 0.2521 0.3040 0.2743 0.2906 0.2556 0.2655 0.2678 0.2540
0.2548
## [11] 0.2495 0.2595 0.2569 0.2538
boxplot.stats(data$fractal dimension mean)
## $stats
## [1] 0.049960 0.057670 0.061515 0.066100 0.078710
##
## $n
## [1] 556
##
## $conf
## [1] 0.06095013 0.06207987
##
## $out
## [1] 0.09744 0.08243 0.08046 0.08980 0.08142 0.08261 0.09296
0.08116
## [9] 0.08104 0.08743 0.08450 0.07950 0.09502 0.09575 0.07976
```

Observamos que aparecen algunos valores extremos, no obstante asumimos que estos valores son factibles y que se pueden dar casos que generen que el área de la célula, por ejemplo, sea más grande. Esto puede ser un factor influyente en el diagnóstico, por lo que inicialmente se

decide no tratar los valores extremos. Más adelante si resultará contraproducente para la predicción, se tomarían medidas.

Procedemos a guardar el dataset en un documento en formato .csv

```
write.csv(data, "clean_breast.csv")
```

#### Análisis de los datos

## Selección de los grupos de datos a analizar

Antes que nada vamos a estandarizar las variables numéricas.

```
# Importamos la libreria dplyr y ggplot2
library(dplyr)
library(ggplot2)

# Utilizaremos mutate_if y luego is.numeric, ya que tenemos variables continuas
data_scaled <- mutate_if(data, is.numeric, scale)</pre>
```

A continuación sacaremos las correlaciones entre las variables numéricas:

```
cor(data[, 2:11])
##
                         radius mean texture mean perimeter mean
area mean
## radius mean
                           1.0000000 0.343924917
                                                       0.9977642
0.9880838
## texture mean
                           0.3439249 1.000000000
                                                       0.3506461
0.3380214
## perimeter mean
                           0.9977642 0.350646087
                                                       1.000000
0.9871877
## area mean
                           0.9880838 0.338021366
                                                       0.9871877
1.0000000
## smoothness mean
                           0.1572871 0.004953432
                                                       0.1949979
0.1659458
## compactness mean
                           0.4922906 0.257085264
                                                       0.5446777
```


0.4862017 ## concavity_mean 0.6774488	0.6668914 0.33	22500457	0.7075658
## concave.points_mean 0.8184491	0.8170052 0.3	15583845	0.8464296
## symmetry_mean 0.1528633	0.1509377 0.09	93134433	0.1870471
<pre>## fractal_dimension_mean -0.2784674</pre>	-0.3057228 -0.00	55109125 -	-0.2542666
##	smoothness_mean	compactness_me	ean
concavity_mean			
## radius_mean 0.6668914	0.157287059	0.49229	006
## texture_mean 0.3225005	0.004953432	0.25708	353
<pre>## perimeter_mean 0.7075658</pre>	0.194997902	0.54467	777
## area mean	0.165945785	0.48620	17
0.6774488			
## smoothness mean	1.00000000	0.65865	96
0.5212938			
## compactness mean	0.658659596	1.00000	000
0.8804934			
## concavity_mean 1.0000000	0.521293833	0.88049	34
<pre>## concave.points_mean 0.9189655</pre>	0.553796101	0.82659	146
## symmetry_mean 0.5085856	0.556780020	0.60999	32
<pre>## fractal_dimension_mean 0.3541342</pre>	0.591158775	0.58429	77
##	concave.points_me	<del></del>	
## radius_mean	0.8170		
## texture_mean	0.3155		
<pre>## perimeter_mean ""</pre>	0.84642		
## area_mean	0.8184		
## smoothness_mean	0.5537		
## compactness_mean	0.8265		
## concavity_mean	0.9189	0.50858	3564

```
## concave.points mean
                                     1.0000000
                                                  0.47078756
## symmetry mean
                                     0.4707876
                                                   1.00000000
## fractal dimension mean
                                     0.1815634
                                                  0.47726915
##
                           fractal dimension mean
## radius mean
                                      -0.30572283
## texture mean
                                      -0.06510913
## perimeter mean
                                      -0.25426657
## area mean
                                      -0.27846739
## smoothness mean
                                       0.59115878
## compactness mean
                                       0.58429773
## concavity mean
                                       0.35413420
## concave.points mean
                                       0.18156336
## symmetry mean
                                       0.47726915
## fractal dimension mean
                                       1.00000000
```


Observamos que radius\_mean se relaciona fuertemente con perimeter\_mean (0.997), area\_mean (0.988) y concave.points\_mean (0.817). concave.points\_mean se relaciona fuertemente con concavity mean (0.9189655), perimeter mean (0.9189655) y compactness mean (0.8265946).

Procedemos a graficar las distintas variables junto con la variable clasificatoria para hacer una primera estimación de cuales serán las variables con más peso.


```
ggplot(data = data_scaled,aes(x=radius_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```









```
ggplot(data = data_scaled,aes(x=perimeter_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```




```
ggplot(data = data_scaled,aes(x=area_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```










```
ggplot(data = data_scaled,aes(x=compactness_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```




```
ggplot(data = data_scaled,aes(x=concavity_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```








```
ggplot(data = data_scaled,aes(x=symmetry_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```



```
ggplot(data =
data_scaled,aes(x=fractal_dimension_mean,fill=diagnosis))
+geom_histogram(binwidth =1)
```



Se observa que radius\_mean, perimeter\_mean, area\_mean, concave.points\_mean y compactness\_mean podrían ser relevantes para explicar el diagnóstico. Ya que a partir de un cierto nivel solo encontramos registros de un tipo u de otro.

# Comprobación de la normalidad y homogeneidad de la varianza

Para comprobar la normalidad utilizaremos el test Saphiro

```
shapiro.test(data_scaled$radius_mean)
##
## Shapiro-Wilk normality test
##
```

```
data scaled$radius mean
## data:
## W = 0.93534, p-value = 8.644e-15
shapiro.test(data scaled$texture mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$texture mean
## W = 0.97703, p-value = 1.169e-07
shapiro.test(data scaled$perimeter mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$perimeter mean
## W = 0.92972, p-value = 1.762e-15
shapiro.test(data scaled$area mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$area mean
## W = 0.85468, p-value < 2.2e-16
shapiro.test(data scaled$smoothness mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$smoothness mean
## W = 0.98488, p-value = 1.593e-05
shapiro.test(data scaled$compactness mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$compactness mean
## W = 0.91747, p-value < 2.2e-16
```

```
shapiro.test(data scaled$concavity mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$concavity mean
## W = 0.86574, p-value < 2.2e-16
shapiro.test(data scaled$concave.points mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$concave.points mean
## W = 0.8862, p-value < 2.2e-16
shapiro.test(data scaled$symmetry mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$symmetry mean
## W = 0.97019, p-value = 3.329e-09
shapiro.test(data scaled$fractal dimension mean)
##
##
    Shapiro-Wilk normality test
##
## data: data scaled$fractal dimension mean
## W = 0.92142, p-value < 2.2e-16
```

De acuerdo con el test de Shapiro, no podemos asumir normalidad en ninguna de las variables, ya que el p-valor es menor que 0.05. No obstante de acuerdo con el teorema del limite central, para muestras grandes (n > 30) podemos asumir normalidad.

# Aplicación de pruebas estadísticas para comparar los grupos de datos

A continuación vamos a utilizar el algoritmo k-means para crear un modelo predictivo. Utilizaremos k = 2 ya que sabemos de antemano que k sería 2

```
data_clusters2 <- kmeans(data_scaled[, 2:11], 2)

table(data_clusters2$cluster,data_scaled$diagnosis)

##
## B M
## 1 4 162
## 2 340 50</pre>
```

Podemos ver que el modelo con k-means, ha clasificado correctamente 340 resultados benignos y 162 resultados malignos, con una precisión del modelo de cerca del 90%.

A continuación vamos a aplicar un modelo de regresión logística.

```
logit model <-</pre>
qlm(formula=diagnosis-radius mean+texture mean+perimeter mean+area mea
n+smoothness mean+compactness mean+concavity mean+concave.points mean+
symmetry mean+fractal dimension mean, data=data scaled,
family=binomial)
summary(logit model)
##
## Call:
## glm(formula = diagnosis ~ radius mean + texture mean +
perimeter mean +
##
       area mean + smoothness mean + compactness mean + concavity mean
+
##
       concave.points mean + symmetry mean + fractal dimension mean,
##
       family = binomial, data = data scaled)
##
## Deviance Residuals:
                         Median
##
       Min
                   10
                                       30
                                                Max
## -1.94745 -0.15493 -0.04012
                                  0.00490
                                            2.91079
##
## Coefficients:
##
                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)
                           0.66975
                                      0.56525
                                                        0.2361
                                                1.185
## radius mean
                          -7.18764
                                     12.95109 -0.555
                                                        0.5789
## texture mean
                          1.63427
                                      0.27384 5.968 2.4e-09 ***
```

```
## perimeter mean
                                    12.11280 -0.142
                         -1.72113
                                                       0.8870
## area mean
                         14.01933
                                     5.90537
                                               2.374
                                                       0.0176 *
## smoothness mean
                          1.05575
                                     0.44371
                                              2.379
                                                       0.0173 *
## compactness mean
                                     1.06982 -0.075
                         -0.08063
                                                       0.9399
## concavity mean
                                     0.64662 1.026
                                                       0.3047
                          0.66370
## concave.points mean
                          2.57527
                                     1.09796 2.346
                                                       0.0190 *
## symmetry mean
                                     0.29168 1.533
                                                       0.1253
                          0.44706
## fractal dimension mean -0.47588
                                     0.60437 -0.787
                                                       0.4310
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##
      Null deviance: 739.14 on 555 degrees of freedom
## Residual deviance: 146.02 on 545 degrees of freedom
## AIC: 168.02
##
## Number of Fisher Scoring iterations: 9
librarv(caret)
confusionMatrix(table(predict(logit model, type="response") >=
0.5,data scaled$diagnosis == "M"))
## Confusion Matrix and Statistics
##
##
##
          FALSE TRUE
##
    FALSE
            334
                  19
##
    TRUE
             10 193
##
##
                 Accuracy : 0.9478
##
                   95% CI: (0.9259, 0.9648)
##
      No Information Rate: 0.6187
##
      P-Value [Acc > NIR] : <2e-16
##
##
                    Kappa : 0.8885
##
   Mcnemar's Test P-Value: 0.1374
##
```

```
##
##
               Sensitivity: 0.9709
##
               Specificity: 0.9104
            Pos Pred Value: 0.9462
##
##
            Neg Pred Value: 0.9507
                Prevalence: 0.6187
##
            Detection Rate: 0.6007
##
      Detection Prevalence: 0.6349
##
##
         Balanced Accuracy: 0.9407
##
##
          'Positive' Class : FALSE
##
```

#### **Conclusiones**

Podemos concluir que el modelo de regresión logística clasifica de mejor forma los datos que el modelo basado en k-means. Con el primero obtenemos una precisión cercana al 95% mientras que con k-means nos quedamos en el 90%.

## Contribuciones al trabajo

CONTRIBUCIONES FIRMA

Investigación previa Victor Mascarell Ascó

Redacción de las respuestas Victor Mascarell Ascó

Desarrollo código Victor Mascarell Ascó